

Федеральное государственное автономное образовательное учреждение
высшего образования
«Национальный исследовательский университет «Высшая школа экономики»
Факультет гуманитарных наук
Фундаментальная и компьютерная лингвистика

О Т Ч Е Т
по учебной практике

Выполнил(а) студент(ка)

Краснова Виктория Александровна
(ФИО)

(подпись)

№ группы **БКЛ-231**

Проверил(а):

(должность, ФИО руководителя)

(подпись)

25.09.2026
(дата)

Отчет по практике

1. Введение

Цель учебной практики: сравнение методов автоматической расстановки знаков препинания и восстановления регистра для потоковой выдачи русской речи (ASR) для переводчика.

Задачи:

- 1) Обзор литературы по теме
- 2) Подбор датасетов
- 3) Реализация прототипов пунктуаторов
- 4) Сравнение стратегий обработки потоков
- 5) Выбор и подсчет метрик
- 6) Анализ результатов и выявление системных ошибок моделей

2. Содержательная часть.

Практика состояла из двух основных этапов.

На первом этапе была изучена по автоматической расстановке знаков препинания в распознанном тексте, поступающем сегментами. Были рассмотрены 4 ресурса:

- 1) *Автоматическая расстановка знаков препинания в распознанном тексте методами машинного обучения* (studnauka.itmo.ru)

Предлагает подход на основе мультиклассовой классификации с использованием легковесного RuBERT (430 тыс. параметров). Модель анализирует фиксированный контекст из 6 слов и предсказывает знак после центрального слова. Классы: нет знака, запятая, конец предложения.

- 2) *Модель kontur-ai/sbert_punc_case_ru* (Hugging Face)

Описывает модель на базе SBERT. Изначально она обучена на цельных предложениях: принимает текст в нижнем регистре, возвращает пунктуацию и заглавные буквы. Для потоковой задачи предлагается адаптация через буферизацию (2–3 сегмента) или скользящее окно с голосованием.

3) *Online Punctuation Restoration using ELECTRA Model for streaming ASR Systems* (isca-archive.org)

Представляет подход на основе ELECTRA-Small для потоковых ASR-систем. Для каждого поступающего слова модель предсказывает знак после него, используя асимметричное окно контекста (до 100 предыдущих слов и до 3 следующих).

4) *Efficient Punctuation Restoration via Weighted Lookahead Scoring Method for Streaming ASR Systems* (arxiv.org)

Развивает идею потоковой классификации (ELECTRA-Small) с использованием метода взвешенной оценки с небольшим заглядыванием вперед (Weighted Lookahead Scoring). Это позволяет балансировать между минимальной задержкой (latency) и точностью предсказания.

Главный вывод по литературе: во всех рассмотренных работах подходом является мультиклассовая классификация позиции после слова с использованием ограниченного контекстного окна. Везде в качестве метрик использованы классические precision, recall, F1. Это обосновывает выбранный в практике подход: сравнение моделей именно по этим метрикам с отдельным учетом классов знаков (точки, запятые, прочие) и регистра.

На втором этапе были реализованы пунктуаторы на базе четырёх моделей. Для каждой модели использовались две стратегии потоковой обработки: буфер (buffer_size=1, каждый сегмент обрабатывается отдельно) и скользящее окно (context_size=5, модель видит до 5 предыдущих сегментов, но из вывода берётся только последний сегмент). Для результатов их работы были подсчитаны метрики.

Модель	Ссылка	Задача
SbertPuncCase	huggingface.co/kontur-ai/sbert_punc_case_ru	Токенная классификация. Восстановление пунктуации

		(точки, запятые, знаки вопроса) и регистра после распознавания речи. Обучена на расшифровках интервью.
Spell-Corrector-RU-4B	huggingface.co/melsmm/Spell-Corrector-RU-4B	LLM на базе RuadaptQwen3-4B-Instruct, дообученная через LoRA. Исправление орфографических, пунктуационных и регистровых ошибок в русскоязычных текстах. Обучена на синтетических и реальных парах «ошибка - исправление».
GigaChat-3-Ultra	gigachat.ru	Универсальная генеративная модель. Использовалась через API с промптом на расстановку пунктуации.
SAGE	huggingface.co/ai-	T5 на базе FRED-

	forever/sage-v1.1.0	T5-1.7B. Исправление орфографии, пунктуации и регистра.
--	---------------------	---

3. Организация

Центр искусственного интеллекта Сбербанка

4. Описание профессиональных задач, решаемых студентом на практике *(в соответствии с целями и задачами программы практики и индивидуальным заданием).*

- 1) Реализация прототипов SbertBufferPunctuator, SbertWindowPunctuator, SpellCorrectorPunctuator, SpellCorrectorWindowPunctuator, GigaChatPunctuator, GigaChatWindowPunctuator, SagePunctuator, SageWindowPunctuator.
- 2) Разработка функции подсчета метрик.
- 3) Анализ результатов.

5. Выполнение индивидуального задания.

В ходе практики мной было реализовано восемь прототипов пунктуаторов на базе четырёх моделей, каждая в двух режимах: буфер (buffer_size=1) и скользящее окно (context_size=5). Для всех прототипов был проведён сравнительный анализ по метрикам Precision, Recall, F1, Visibility и Extra, а также по задержке.

Метрики показывают, что увеличение окна дает незначительный прирост качества. Для GigachatUltra – даже ухудшает качество.





Значения метрик на 1 датасете:



Лучшее качество по запятым: SpellCorrectorWindow5 (F1 = 0.7363).



Лучшее качество по заглавным: SbertWindow5 (F1 = 0.7845).



Лучшее качество по остальным знакам: GigaChatUltra (F1 = 0.3210), но это всё равно плохой результат.

Лучший баланс: SbertBuffer — приемлемое качество при минимальной задержке.









Метод подсчета метрик:

Шаг 1. Токенизация. Текст разбивается на пары (слово, знак_после_слова). Это важно, т.к. при проходе через модель могли произойти незначительные изменения со словами, но из-за этого посимвольное сравнение будет давать ложные результаты.

Шаг 2. Выравнивание. Два списка токенов (эталон и гипотеза) выравниваются по словам. Используется гибридный критерий похожести слов:

для коротких слов (≤ 4 символов) — абсолютный порог;

для длинных — по Левенштейну.

Шаг 3. Подсчёт промежуточных метрик. Для каждой группы сопоставляются пары слов и считаются счётчики:

tp — модель поставила знак, и он правильный;

fp — модель поставила знак, но его не должно было быть;

fn — знак должен был быть, но модель его не поставила;

total_ref — всего знаков этой группы в эталоне;

total_hyp — всего знаков этой группы в предсказании;

visibility — сколько раз модель поставила хоть какой-то знак на месте нужного.

Шаг 4. Расчёт метрик.

Precision = $tp / (tp + fp)$

Recall = $tp / total_ref$

F1 = $2 \times P \times R / (P + R)$

Visibility = $visibility_hit / total_ref$

Extra = fp

Результаты:

- 1) Знаки, кроме точек и запятых, трудно восстанавливаются. Это может быть связано с дисбалансом класса.
- 2) Расширение окна не дает улучшения качества и иногда даже влияет негативно.
- 3) Модели ставят много лишних точек и запятых.
- 4) Лучший баланс – SbertBuffer.
- 5) Sage самая быстрая модель.

Отрывок текста, восстановленный моделью SbertBuffer:

Да. Привет. Мне очень приятно тут быть, потому что я на самом деле выпускник Высшей школы экономики. Так что вдвойне рад вас видеть. Да, я закончил факультет политологии в 2007 году, и я очень удивлён, сколько здесь студентов. В пятницу вечером я, к своему стыду, особенно на первых курсах не составил бы вам компанию. Моё выступление тоже про будущее. И я немножко вас попугаю, про немножко мрачное будущее. Вы знаете компанию, в которой я работаю? Лаборатория Касперского. Зрители. Да. Антон Шингарёв. Хорошо. Приятно. Для понимания контекста.

6. Заключение

В ходе выполнения данной практики я приобрела опыт разработки прототипов пунктуации, работы с моделями машинного обучения, работы с сегментированным текстом и разработки методов оценки расстановки пунктуации в текстах. У работы есть перспектива – доработка метода под работу с другими языками.

7. Приложения (*графики, схемы, таблицы, алгоритмы, иллюстрации и т.п.*).

Приложение / Приложение отсутствует

Ссылка на репозиторий с кодом и файлом с результатами:
https://github.com/ViktoriaKrasnova15/punctuation_for_asr

8. Отзыв руководителя с рекомендованной оценкой.